

基于 SE-ResNeXt 的高血压视网膜病变检测

王智烨 王昕源 童浩宇

摘要: 高血压视网膜病变 (HR) 是由持续升高的血压引起的视网膜表现。计算机辅助诊断在早期识别高血压视网膜病变方面发挥着重要作用, 其诊断准确率高、时间效率高、所需资源少。目前, 由于数据集数量有限, 可用于高血压视网膜病变检测的计算机化系统非常少, 深度学习面对小数据集常出现过度拟合现象, HR 检测仍有很大的进步空间。在这项工作中, 本小组以 SE ResNeXt50 为基础, 利用预训练的初始基线模型开发了一种基于小数据集的新型 HR 检测方法。本小组通过数据增广等数据预处理方法来进行模型训练, 这可用于避免过拟合, 并提高对较小数据集的泛化能力。此外, 本小组比较尝试了多种图像增强方法, 以训练出效果最好的模型。本小组的方法在 HRDC 2023 高血压视网膜病变诊断挑战赛中被证明是有效的, 最终结果 Kappa 达到 0.4562, F1 达到 0.6573, Specificity 达到 0.8056, 在挑战排行榜上排名第 2。这项工作解决了准确和有效的高血压视网膜病变诊断和干预的关键需求。项目代码详见 <https://github.com/VinylCat/CS3511>。

Detection of Hypertensive Retinopathy Based on SE-ResNeXt

Zhiye Wang, Xinyuan Wang, Haoyu Tong

Abstract: Hypertensive retinopathy (HR) is a retinal manifestation caused by persistently elevated blood pressure. Computer-aided diagnosis plays an important role in the early identification of hypertensive retinopathy with high diagnostic accuracy, time efficiency, and low resource requirements. Currently, there are very few computerized systems available for the detection of hypertensive retinopathy due to the limited number of datasets, deep learning is often overfitted in the face of small datasets, and there is still a lot of room for improvement in HR detection. In this work, our team developed a novel HR detection method based on small datasets using a pre-trained initial baseline model based on SE ResNeXt50. This team trained the model through data preprocessing methods such as data augmentation, which can be used to avoid overfitting and improve generalization to smaller datasets. In addition, our team comparatively tried multiple image enhancement methods to train the model with the best results. Our method proved to be effective in the HRDC 2023 Hypertensive Retinopathy Diagnostic Challenge. It achieved Kappa of 0.4562, F1 of 0.6573 and Specificity of 0.8056, ranking 2nd on the challenge leaderboard. This work addresses the critical need for accurate and effective hypertensive retinopathy diagnosis and intervention. The project code is available at <https://github.com/VinylCat/CS3511>.

Key word: Hypertensive retinopathy, Deep learning, SE ResNeXt, Image augmentation

1 简介与意义/Introduction

1.1 项目意义和依据/Significance

高血压视网膜病变(Hypertension retinopathy, HR)是指由高血压引起的视网膜损伤。视网膜是眼睛的一个组织层，负责捕捉和传输图像信息。血压升高最初会引起视网膜的变化，导致视网膜动脉痉挛性收缩。其存在各种临床症状：如小动脉狭窄[1]、动静脉切口(AVN)[2]、渗出物[3]、棉絮斑(CWS)[4]、视盘肿胀[5]等。

多项研究表明，HR 是多种疾病的生物标志物，包括心血管风险[8]和靶器官损伤。眼睛是唯一可以无创、简便地通过眼底镜检查直接发现早期微循环变化的器官。在早期阶段，这些变化的症状是看不见的。慢性疾病的早期微循环异常可以在对健康造成重大影响之前被发现。发现早期 HR 患者将有助于及时有效的治疗，防止失明。因此，常规 HR 筛查对于早期发现和随后处理包括失明在内的严重健康问题至关重要。然而人工 HR 诊断费时不方便，需要专业的技能和经验[11]。然而，由于初级医疗保健设施不足，人工 HR 诊断相当困难，尤其是在发展中国家、农村和偏远地区。另一方面，自动化人力资源诊断有效地解决了上述问题：它更省时，需要更少的人力资源，并提高了诊断的准确性[12]。

1.2 本方法/系统框架/Article Structure

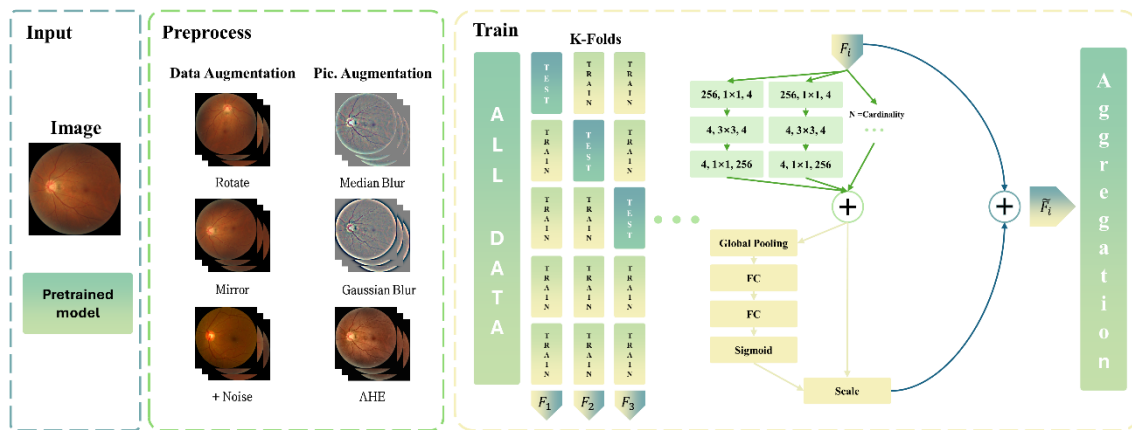


图 1 系统框架概览

本小组提出的框架如图 1 所示。本小组的研究将以 SE ResNeXt50 为基础，利用预训练的初始基线模型进行迁移学习。首先通过数据增广、图像增强等数据预处理方法来进行模型训练。本小组先通过旋转、镜像图片并添加椒盐噪声以增广数据。特别地，本小组分别采用了加权和和高斯模糊、中值滤波和自适应直方图均衡化三种方法进行图像增强来防止过拟合。另外，在训练过程中，本小组使用多折训练方法，在最终判断时使用多折模型来综合预测最终的结果。这将在第 3 节中具体介绍。

2 相关工作/Related Works

2.1 高血压视网膜病变检测

深度学习方法在诊断眼底图像上的各种眼科疾病方面取得了显著进步。针对糖尿病视网膜病变 (DR), Dai 等人[13]提出了一种名为 DeepDR 的深度学习系统, 用于实时图像质量评估、病变检测和 DR 分级等多种用途。Hou 等人[14]提出了一种跨场变换器, 利用双场眼底图像的相关性进行 DR 筛查。Xue 等人[15]设计了基于深度学习的网络, 用于基于红外眼底图像诊断白内障 DR。Guo 等人[16]提出了一种针对小病变区域的多尺度特征融合方法, 确保了高水平的网络响应。他们还采用了多通道二进制损失来解决类和损失不平衡的问题。

与上述常见眼科疾病相比, 通过深度学习方法对高血压视网膜病变进行自动分类的研究在很大程度上仍处于探索阶段。传统的基于 ML 的 HR 检测方法使用大量的预处理、特定领域的手工特征和分类器, 如支持向量机 (SVM)、传统神经网络模型等。Agurto 等人使用直方图拉伸、颜色归一化、视盘 (OD) 定位和动脉/静脉 (A/V) 识别等方法对眼底图像进行预处理。他们使用了动静脉比率 (AVR)、迂曲指数和基于纹理的特征, 通过选择整个 OD 区域的感兴趣区 (ROI), 并使用回归分类器进行二元 HR 分类[17]。Akbar 等人使用对比度增强、A/V 分类、OD 定位进行预处理, 并使用 SVM 分类器计算 AVR 进行二元 HR 分类[18]。

然而, 传统的 HR 检测方法需要大量的增强, 有时会导致模糊 (由于低通滤波器)、信息丢失 (由于线性滤波器)、过度增强结果和其他伪影的产生 (有时由于直方图均衡化) [19]。此外, 这些方法还使用其他一些预处理步骤, 如准确的血管分割、OD 定位、ROI 选择和 A/V 分类。这些方法通常需要手工制作特定领域的特征, 这是一项繁琐而费力的工作[20]。而且, 其性能在很大程度上依赖于定义明确的特征工程; 因此, 它需要领域专业知识和特征工程知识。

另一方面, DL 技术使用基于表示的学习方法, 利用大量非线性模块自动发现原始图像中复杂的局部和全局特征。DL 不需要特定领域的手工特征, 而且需要的预处理非常有限。Abbas 等人[21]提出了用于二元 HR 分类的深度残差学习和 CNN。不过, 他们的方法使用了许多糖尿病视网膜病变数据集, 如 DRIVE[22]、DIARETDB0&1[23]、DR1&DR2[24]和 DRHAGIS [25]来训练和评估 HR。除了 CNN, 常见的图像分类网络还有 VGG[26]、Inception[27]、ResNet[28]、DenseNet[29]。Zhang[30]等人使用预训练的 Inception-v3 网络进行 HR 检测。然而, 这些方法的性能仍然较低, 有待进一步提高。

3 研究内容与方法/Contents and Methods

3.1 数据集来源

本小组的使用 CodaLab 竞赛官方提供的 712 张眼底照片作为训练集, 同时在此基础上对

其进行了数据增广。最终获得了 5696 张眼底照片作为训练集，其中标签为 0 的照片共有 3360 张，标签为 1 的照片共有 2336 张。

3.2 数据预处理

3.2.1 数据增广

考虑到训练集的数量大小有限，为了使得模型有着更强的泛化能力，尽量避免过拟合情况的出现，本小组对于训练集的图像进行了数据的增广。数据增广是对数据进行扩充的方法的总称，可以增加训练集的样本数量，可以有效缓解模型过拟合的情况，也可以给模型带来更强的泛化能力，可以迫使网络学习到更鲁棒的特征，从而使模型拥有更强的泛化能力。

考虑到训练中提供的所有眼球照片大小相同且都和图像边缘相切，因此平移变换的需求并不大。于是本小组分别采用旋转 90, 180, 270 度和翻转图片以及向图片中添加椒盐噪声的方法进行数组增广。其中椒盐噪声也称为脉冲噪声，主要由图像的极值组成，在视觉上表现为黑白相间的亮暗点，添加噪声可以增强模型的鲁棒性。

3.2.2 图像增强

图像增强是通过一定手段对原图像附加一些信息或变换数据，有选择地突出图像中感兴趣的特征或者抑制(掩盖)图像中某些不需要的特征，使图像与视觉响应特性相匹配。提高模型性能的一种直观方法是简单地提高输入图像的质量。比如调整图像的对比度，使得图像中的特征更加清晰，而这在医学影像识别上是非常重要的。从图 2 中可以看到，对于诊断高血压视网膜病变 Hemorrhages, Hard Exudates, Cotton Wool 等关键部位非常重要。通过图像增强技术可以突出这一部分内容，从而使得模型能够更好的学习到图像的特征并进行判断。

本小组分别采用了加权和高斯模糊、中值滤波与自适应直方图均衡化三种方法进行图像增强。




图 2 视网膜病变示意图

自适应直方图均衡化 (AHE) 是一种用于增强图像对比度的计算机图像处理技术。与全局直方图均衡化不同，AHE 算法考虑了图像的局部特性，通过计算每个像素邻域的直方图来调整像素值，从而改进图像的局部对比度并获得更多的图像细节。这种方法通常用来有效增加图像的全局对比度，尤其是当图像的有用数据的对比度相当接近的时候。通过这种方法，亮度可以更好地在直方图上分布。这样就可以用于增强局部的对比度而不影响整体的对比度，直方图均衡化通过有效地扩展常用的亮度来实现这种功能。

高斯模糊是一种数据平滑技术，适用于多个场合。高斯模糊是对整幅图像进行加权平均的过程，每一个像素点的值都由其本身和邻域内的其他像素值经过加权平均后得到。高斯模糊的具体操作是：用一个卷积核扫描图像中的每一个像素，用模板确定的邻域内像素的加权平均灰度值去替代模板中心像素点的值。

3.3 模型选择

本小组选用了 SE ResNeXt50 作为训练模型，并利用预训练的初始基线模型进行迁移学习。相较于经典的 ResNet[28]模型，其主要做出了以下两种修改。

3.3.1 聚合转换

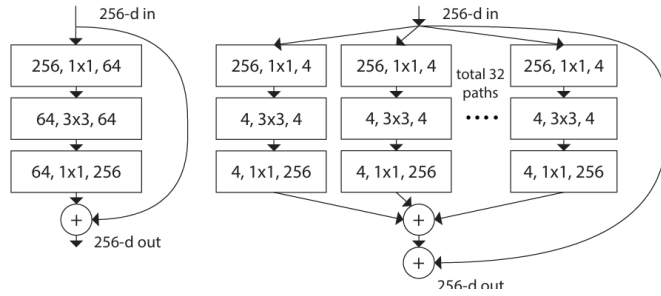


图 3[33] 左：ResNet 块结构。右：Cardinality=32 时的 ResNeXt

ResNeXt[33]修改了 ResNet 中的块结构，相较于传统神经网络宽度和深度两个维度，通过增加了每一个块的内部路径数量，即 Cardinality 的数量，获得了一个新可测量的维度。依靠这种分组卷积的方式，在深度和宽度使得现有模型的收益开始递减时，将输入通道和输出通道分为若干组，在每组内进行卷积操作。每组结果的聚合转换形式如公式 1 所示：

$$\mathcal{F}(x) = \sum_{i=1}^C \mathcal{T}_i(x) \quad (1)$$

其中 $\mathcal{T}_i(x)$ 作为一个抽象函数，类似于一个简单的神经元， \mathcal{T}_i 将 x 投影到一个嵌入空间，并对其转换。 C 是待聚合的转换集的大小，即 Cardinality。

利用聚合转换，使用平行堆叠相同拓扑结构的块替换原先 ResNet 中的三层卷积块，在不明显增加参数量的情况下提高了模型的表征能力与准确率。

3.3.2 注意力机制

SENet[34]中提出的 SE 模块主要包含 Squeeze 和 Excitation 两个关键步骤，通过学习的方式来自动获得每个特征通道的重要程度，并以此为依据来提升有用的特征并且抑制作用不大的特征，达到显式地建模特征通道之间的相互依赖关系。




图 4[34] SE 块

Squeeze 是全局信息的嵌入过程，其目的是聚合空间维度（宽度和高度）上的信息。 F_{sq} 通过全局平均池化对 U 的每个通道执行空间维度的压缩，产生一个 $1 \times 1 \times C$ 维度的向量，代表每个通道的全局特征。

Excitation 利用 Squeeze 的输出进行特征重校准，目的是通过学习各个通道之间的相互依赖性来动态调整通道特征的相应权重。

最后 F_{scale} 将 Excitation 的输出与 U 中的原始特征图按元素惩罚，得到了重校准后的特征图 \tilde{X} ，使得维度依旧保持 $H \times W \times C$ 。该过程强化了重要通道的特征相应，抑制了不必要的特征。




图 5[34] 运用 SE 模块的 ResNet

SE 模块可以嵌入含有 skip-connections 的模块中。如图 5 所示：当输入 X 通过 ResNet 模块后，通过全局平均池化层完成 Squeeze 操作，并由 FC，ReLU 和另一个 FC 以及 Sigmoid 函数负责学习每个通道的重要性权重。利用以上的操作，在残差网络中引入了 SE 通道注意力机

制。

3.4 RAdam优化器

RAdam（Rectified Adam）[35]作为 Adam 优化器的改进，解决了 Adam 优化器在某些情况下可能表现出的不稳定性问题。

传统的自适应学习率优化器，如 Adam、RMSprop 等，可以帮助深度神经网络模型更加的收敛。然而，在训练的早期阶段，由于训练的样本数量有限，自适应学习率会存在较大的方差。

因此，Radam 增加了自适应学习率的校正机制，通过分析梯度的方差，能够在训练的早期阶段减少学习率的波动，以提供更稳定的优化过程。

4 实验结果与分析/Experiment Results and Analysis

4.1 与baseline模型的对比

其中，学习率 learning rate 设置为 0.001，训练轮数 epochs 设置为 10。

Model\Epochs	10	20	30	40
ResNet50	62.50%	60.00%	76.66%	75.00%
se_resnext50_32x4d(Ours)	91.58%	93.44%	93.45%	92.99%

表 1 网络效果对比

从表 1 中可以看出，与 ResNet50 相比较，本小组的模型在测试集上能够超越 ResNet50 约 10%的准确率，由于使用了注意力机制与分组卷积技术，在 ResNet 的基础上实现了改进，于是能够达到更好的效果。同时经过我们的实验，为了避免过拟合得到的最适合的 epochs 训练轮数为 10。




图 6 图像增强方法对比

4.2 图像增强方法对比

在实验中，本小组采用了不同种类的图片增强方法来获得增强的图片信息。在本节中，本小组进行消融实验，以更好地了解使用不同的图片增强方法对模型运行结果的影响。所有实验在基于 CodaLab 竞赛官方提供的 712 张眼底照片的增广后的 5696 张照片的训练集上进行实验。图像增强的方法遵循在 3.2.2 章中描述的方法。学习率 learning rate 设置为 0.001，训练轮数 epochs 设置为 10，模型使用开源的预训练模型 se_resnext50_32x4d 并进行微调。

Augment Method	Accuracy(Online)
Adaptive Histogram Equalization	58.60%
Weighted Gaussian Blur	63.97%
Weighted Median Blur	55.81%

表 2 增广方法-线上测试 Accuracy

从对比实验中可以看到，在三种图像增强方法中，加权和高斯模糊在最终的测试集上表现最好，准确率达到了 63.97%。自适应直方图均衡化其次，准确率达到了 58.60%。从效果对比图中也可以看出，相比 AHE，Gaussian Blur 更能够将图片中的血管等关键部位突出，因此得到更好的效果。

5 特色与创新/ Distinctive or Innovation Points

5.1 工作创新

在本小组的项目中，我们首先引入了多种的图片增强方法，包括自适应直方图均衡化，加权和高斯模糊以及加权和中值滤波，可以有效地提取图片中的信息并增强模型效果。此外，本小组引入了 SE 块。SE 块是一种注意力模块，其结构很简单，可以直接在现有的最先进的体系结构中使用，方法是将组件替换为 SE 对应组件，从而可以有效地提高性能。SE 块在计算上也是轻量级的，并且仅略微增加了模型复杂性和计算负担。

在模型训练时，我们类比多折交叉验证，引入了多折训练的方法。将训练集分为多个训练集和验证集，每一个小训练集用来训练一个模型，在最终判断时使用多折获得的多个模型数据，分别用来预测结果并在推理里结合多个预测结果(代码中表现为取平均)做出最终的预测结果。

6 补充说明：

6.1 术语：

K 折交叉验证：交叉验证，有时亦称循环估计，是一种统计学上将数据样本切割成较小子集的实用方法。于是可以先在一个子集上做分析，而其它子集则用来做后续对此分析的确

认及验证。一开始的子集被称为训练集。而其它的子集则被称为验证集或测试集。将训练集分割成 k 个子样本，一个单独的子样本被保留作为验证模型的数据，其他 $k - 1$ 个样本用来训练。交叉验证重复 k 次，每个子样本验证一次，平均 k 次的结果或者使用其它结合方式，最终得到一个单一估测。这个方法的优势在于，同时重复运用随机产生的子样本进行训练和验证，每次的结果验证一次。

优化器(Optimizer): 在深度学习中，优化器是指用于最小化（或最大化）损失函数的算法。损失函数是衡量模型预测与真实值之间差异的指标，优化器的任务是调整模型的参数，使得损失函数达到最小化的目标。选择合适的优化器通常取决于数据集的特性、模型架构以及训练任务的性质。在实践中，人们常常通过实验和调参来选择最适合特定任务的优化器。常见的优化器有 SGD, Adam 等。

References:

- [1]. P. Modi, T. Arsiwalla, Hypertensive Retinopathy, StatPearls Publishing, 2022. <https://www.ncbi.nlm.nih.gov/books/NBK525980/>.
- [2]. U.T. Nguyen, A. Bhuiyan, L.A. Park, R. Kawasaki, T.Y. Wong, J.J. Wang, P. Mitchell, K. Ramamohanarao, An automated method for retinal arteriovenous nicking quantification from color fundus images, *IEEE Trans. Biomed. Eng.* 60 (11) (2013) 3194–3203, <http://dx.doi.org/10.1109/TBME.2013.2271035>
- [3]. A.D. Henderson, B.B. Bruce, N.J. Newman, V. Bioussé, Hypertension-related eye abnormalities and the risk of stroke, *Rev. Neurol. Dis.* 8 (1–2) (2011) 1.
- [4]. B.K. Triwijoyo, B.S. Sabarguna, W. Budiharto, E. Abdurachman, Deep learning approach for classification of eye diseases based on color fundus images, in: *Diabetes and Fundus OCT*, Elsevier, 2020, pp. 25–57. <http://dx.doi.org/10.1016/B978-0-12-817440-1.00002-4>.
- [5]. A. Grosso, F. Veglio, M. Porta, F. Grignolo, T. Wong, Hypertensive retinopathy revisited: Some answers, more questions, *Br. J. Ophthalmol.* 89 (12) (2005) 1646–1654. <http://dx.doi.org/10.1136/bjo.2005.072546>.
- [6]. Xie, Saining, et al. "Aggregated residual transformations for deep neural networks." *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.
- [7]. Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 7132–7141).
- [8]. C.Y.-I. Cheung, Y. Zheng, W. Hsu, M.L. Lee, Q.P. Lau, P. Mitchell, J.J. Wang, R. Klein, T.Y. Wong, Retinal vascular tortuosity, blood pressure, and cardiovascular risk factors, *Ophthalmology* 118 (5) (2011) 812–818. <http://dx.doi.org/10.1016/j.ophtha.2010.08.045>
- [9]. P. Modi, T. Arsiwalla, Hypertensive Retinopathy, StatPearls Publishing, 2022. <https://www.ncbi.nlm.nih.gov/books/NBK525980/>.
- [10]. Q. Abbas, M.E. Ibrahim, DenseHyper: An automatic recognition system for detection of hypertensive retinopathy using dense features transform and deepresidual learning, *Multimedia Tools Appl.* 79 (41) (2020) 31595–31623, <http://dx.doi.org/10.1007/s11042-020-09630-x>.
- [11]. M. Badar, M. Haris, A. Fatima, Application of deep learning for retinal image analysis: A review, *Comp. Sci. Rev.* 35 (2020) 100203, <http://dx.doi.org/10.1016/j.cosrev.2019.100203>.
- [12]. A. Raj, N.A. Shah, A.K. Tiwari, A novel approach for fundus image enhancement, *Biomed. Signal Process. Control* 71 (2022) 103208.
- [13]. Dai, L., Wu, L., Li, H., Cai, C., Wu, Q., Kong, H., Liu, R., Wang, X., Hou, X., Liu, Y., et al.: A deep learning system for detecting diabetic retinopathy across the disease spectrum. *Nature communications* 12(1), 3242 (2021).
- [14]. Hou, J., Xu, J., Xiao, F., Zhao, R.W., Zhang, Y., Zou, H., Lu, L., Xue, W., Feng, R.: Cross-field transformer for diabetic retinopathy grading on two-field fundus images. In: *2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. pp. 985–990. IEEE (2022).
- [15]. Xue, W., Zhang, J., Ma, Y., Hou, J., Xiao, F., Feng, R., Zhao, R., Zou, H.: Deep learning-based analysis of infrared fundus photography for automated diagnosis of diabetic retinopathy with cataracts. *Journal of Cataract & Refractive Surgery* 49(10), 1043–1048 (2023)
- [16]. Guo, S., Li, T., Kang, H., Li, N., Zhang, Y., Wang, K.: L-seg: An end-to-end unified framework for multi-lesion segmentation of fundus images. *Neurocomputing* 349, 52–63 (2019).
- [17]. C. Agurto, V. Joshi, S. Nemeth, P. Soliz, S. Barriga, Detection of hypertensive retinopathy using vessel measurements and textural features, in: *2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society, IEEE, 2014*, pp. 5406–5409, <http://dx.doi.org/10.1109/EMBC.2014.6944848>.
- [18]. S. Akbar, M.U. Akram, M. Sharif, A. Tariq, S.A. Khan, Decision support system for detection of hypertensive retinopathy using arteriovenous ratio, *Artif. Intell. Med.* 90 (2018) 15–24, <http://dx.doi.org/10.1016/j.artmed.2018.06.004>.
- [19]. S.K. Yadav, S. Kumar, B. Kumar, R. Gupta, Comparative analysis of fundus image enhancement in detection of diabetic retinopathy, in: *2016 IEEE Region 10 Humanitarian Technology Conference, R10-HTC, IEEE, 2016*, pp. 1–5.
- [20]. B. Sahiner, A. Pezeshk, L.M. Hadjiiski, X. Wang, K. Drukker, K.H. Cha, R.M. Summers, M.L. Giger, Deep learning in medical imaging and radiation therapy, *Med. Phys.* 46 (1) (2019) e1–e36, <http://dx.doi.org/10.1002/mp.13264>.
- [21]. Q. Abbas, M.E. Ibrahim, DenseHyper: An automatic recognition system for detection of hypertensive retinopathy using dense features transform and deepresidual learning, *Multimedia Tools Appl.* 79 (41) (2020) 31595–31623, <http://dx.doi.org/10.1007/s11042-020-09630-x>.

- [22]. J. Staal, M.D. Abràmoff, M. Niemeijer, M.A. Viergever, B. Van Ginneken, Ridgebased vessel segmentation in color images of the retina, *IEEE Trans. Med. Imaging* 23 (4) (2004) 501–509, <http://dx.doi.org/10.1109/TMI.2004.825627>.
- [23]. T. Kauppi, V. Kalesnykiene, J.-K. Kamarainen, L. Lensu, I. Sorri, A. Raninen, R. Voutilainen, H. Uusitalo, H. Kälviäinen, J. Pietilä, The diaretdb1 diabetic retinopathy database and evaluation protocol, in: *BMVC*, Vol. 1, 2007, pp. 1–10.
- [24]. R. Pires, H.F. Jelinek, J. Wainer, E. Valle, A. Rocha, Advancing bag-of-visualwords representations for lesion classification in retinal images, *PLoS One* 9 (6) (2014) e96814.
- [25]. S. Holm, G. Russell, V. Nourrit, N. McLoughlin, DR HAGIS—A fundus image database for the automatic extraction of retinal surface vessels from diabetic patients, *J. Med. Imaging* 4 (1) (2017) 014503, <http://dx.doi.org/10.1117/1.JMI.4.1.014503>.
- [26]. Simonyan, Karen and Andrew Zisserman. “Very Deep Convolutional Networks for Large-Scale Image Recognition.” *CoRR* abs/1409.1556 (2014): n. pag, <https://arxiv.org/abs/1409.1556>.
- [27]. C. Szegedy et al., “Going deeper with convolutions,” 2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA, 2015, pp. 1-9, doi: 10.1109/CVPR.2015.7298594.
- [28]. He, Kaiming et al. “Deep Residual Learning for Image Recognition.” 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2015): 770-778, <https://arxiv.org/abs/1512.03385>.
- [29]. G. Huang, Z. Liu, L. Van Der Maaten and K. Q. Weinberger, “Densely Connected Convolutional Networks,” 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017, pp. 2261-2269, doi: 10.1109/CVPR.2017.243.
- [30]. L. Zhang, M. Yuan, Z. An, X. Zhao, H. Wu, H. Li, Y. Wang, B. Sun, H. Li, S. Ding, et al., Prediction of hypertension, hyperglycemia and dyslipidemia from retinal fundus photographs via deep learning: A cross-sectional study of chronic diseases in central China, *PLoS One* 15 (5) (2020) e0233166, <http://dx.doi.org/10.1371/journal.pone.0233166>.
- [31]. Xie, Saining et al. “Aggregated Residual Transformations for Deep Neural Networks.” 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) (2016): 5987-5995. <https://arxiv.org/abs/1611.05431>
- [32]. Hu, Jie et al. “Squeeze-and-Excitation Networks.” 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (2017): 7132-7141, <https://arxiv.org/abs/1709.01507>
- [33]. Xie, Saining, et al. “Aggregated residual transformations for deep neural networks.” *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017.
- [34]. Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 7132-7141).
- [35]. Liu, L., Jiang, H., He, P., Chen, W., Liu, X., Gao, J., & Han, J. (2019). On the variance of the adaptive learning rate and beyond. *arXiv preprint arXiv:1908.03265*.

附录 I

CGI-HRDC 2023 -Hypertensive Retinopathy Diagnosis Challenge Task2 竞赛结果截图（截至 2024/4/28 21:20）。

Results									
#	User	Entries	Date of Last Entry	Team Name	Kappa ▲	F1 ▲	Specificity ▲	Average ▲	CPU Time ▲
1	tiandoufayale	9	04/27/24		0.4938 (1)	0.7004 (1)	0.7444 (15)	0.6462 (1)	0.2503 (24)
2	Onl0n	7	04/28/24		0.4562 (2)	0.6573 (2)	0.8056 (9)	0.6397 (2)	0.1699 (19)
3	Vinylcat	15	04/27/24		0.4395 (3)	0.6294 (6)	0.8500 (7)	0.6397 (3)	0.2725 (25)